



Avaliação de Telemetria Fendt 314: Exposição Operacional Contextual para Inspeção Preventiva

Um modelo híbrido, auditável e integrado a PostgreSQL, API e dashboard para o seguro agrícola

Grupo SEIVA · Enterprise Challenge FIAP × Sompo Seguros

Karina Queiroz de Gennaro, RM 570928¹ · Luis Felipe Bardi, RM 569479¹ · Beatriz de Oliveira Ossola Ribeiro, RM 570190¹

¹ Faculdade de Informática e Administração Paulista (FIAP)

Resumo

Este trabalho apresenta uma avaliação de telemetria para tratores Fendt 314 orientada à prevenção e à priorização de inspeções no contexto do seguro agrícola. A evidência científica parte do histórico observado de uma unidade Fendt 314 publicada no dataset aberto *Agricultural Load Cycles: Tractor Mission Profiles From Recorded GNSS and CAN Bus Data*, da Technical University of Munich, disponível no Zenodo sob licença CC BY 4.0. O problema tratado é deliberadamente mais estreito do que prever dano ou sinistro: como o dataset não possui rótulos de falha, manutenção, indenização ou mau uso, o sistema identifica exposição operacional contextual e não uma probabilidade de perda segurada. A telemetria é organizada em janelas causais de 60 segundos e representada por 43 variáveis agregadas. O modelo híbrido primeiro identifica três regimes de operação por K-Means; em seguida, mede a raridade de cada janela com uma Isolation Forest específica do regime; por fim, exige simultaneamente uma condição física sustentada por pelo menos cinco segundos. A saída é um alerta explicável e um score longitudinal relativo ao histórico de treino em horizontes de 7, 15 e 30 dias. A divisão temporal usa 7.317 janelas de treino, 2.522 de validação e 3.617 de teste posterior. A validação produziu 74 alertas (2,93%) e 68 episódios; o teste temporal consumido produziu 95 alertas (2,63%) e 79 episódios. O artefato `fendt314-hybrid-v2.0.1` está congelado e integrado a uma cadeia executável local: importação observada, PostgreSQL, replay causal, API FastAPI, persistência da decisão e dashboard React. A demonstração versionada importa 152.561 amostras em 105 missões e reproduz 2.522 decisões, enquanto a suíte completa registra 116 testes Python e 25 testes de frontend aprovados. A contribuição do projeto é mostrar, com rastreabilidade e limites explícitos, como um modelo de IA não supervisionado pode sair do experimento e operar em uma aplicação verificável sem ser indevidamente apresentado como diagnóstico mecânico ou modelo atuarial.

Palavras-chave: Seguro Agrícola; Telemetria de Tratores; Fendt 314; Detecção de Anomalias; K-Means; Isolation Forest; Exposição Operacional; Inspeção Preventiva; Explicabilidade; PostgreSQL; FastAPI; Clean Architecture.

1. Introdução

Máquinas agrícolas concentram valor patrimonial elevado e operam sob condições que mudam com implemento, solo, tarefa, clima e conduta operacional. Para uma seguradora, o desafio não é apenas observar um evento depois que ele ocorreu, mas encontrar sinais que ajudem a decidir onde uma inspeção preventiva pode gerar mais valor. Para o gestor da frota, o problema equivalente é transformar milhões de amostras de telemetria em uma indicação compreensível, sem exigir que uma pessoa interprete manualmente RPM, torque, carga, patinagem e engate.

O projeto responde a esse problema com uma pergunta compatível com os dados disponíveis: **em quais janelas a máquina apresenta uma condição física sustentada e, ao mesmo tempo, um comportamento raro para o regime em que está operando?** Essa formulação evita criar um alvo inexistente. Não há no dataset uma coluna que confirme dano, quebra, manutenção ou sinistro; portanto, não há base para treinar ou medir um classificador desses desfechos.

A solução combina conhecimento de engenharia com aprendizado não supervisionado. As regras físicas são explícitas e auditáveis. O K-Means separa contextos de operação. A Isolation Forest mede raridade dentro de cada contexto. O alerta só existe quando os dois lados concordam. Em vez de usar o alerta isolado como sentença, a aplicação agrega exposição física, tempo alertado e episódios em 7, 15 e 30 dias, sempre informando cobertura e confiança.

O modelo é o núcleo do trabalho, mas não fica isolado em um notebook. O projeto inclui importação de dados observados, PostgreSQL, API, reconstrução autoritativa das janelas, frontend e fluxo persistido de inspeção. Assim, a entrega demonstra tanto a construção acadêmica do modelo quanto sua implantação em uma aplicação legível e reproduzível.

2. Caracterização Quantitativa

O dataset de origem reúne 1.245 horas de operação de cinco tratores, com GNSS de alta resolução e dados dos barramentos J1939 e ISOBUS [1]. Este projeto seleciona o arquivo do Fendt 314 e trata o histórico observado dessa unidade como referência científica. A origem temporal absoluta foi recuperada por três âncoras independentes presentes nos arquivos de transporte. As três convergiram para o mesmo epoch UTC, permitindo reconstruir aproximadamente 226 horas, 80 dias com telemetria e 555 missões entre abril e dezembro de 2024.

A separação experimental é cronológica, nunca aleatória por janela. Treino e validação orientam seleção e congelamento; o teste representa um período posterior e foi aberto uma única vez. A Tabela 1 resume o censo utilizado.

Conjunto	Intervalo	Missão analítica	Janelas	Resultado principal
Treino	26/04 a 30/08/2024	ajustar pré-processamento, regimes, detectores e baseline	7.317	referência aprendida
Validação	07/09 a 19/10/2024	selecionar pelos gates predefinidos	2.522	74 alertas; 68 episódios
Teste temporal	21/10 a 04/12/2024	avaliação final posterior	3.617	95 alertas; 79 episódios
Demo versionada	07/09 a 19/10/2024	provar execução ponta a ponta	152.561 amostras; 105 missões	2.522 janelas; 74 alertas

Tabela 1. Divisão temporal, finalidade e volume da evidência utilizada.

Na validação, 40,40% das janelas satisfizeram ao menos uma regra física e 7,26% dessas janelas também ultrapassaram o limiar de raridade contextual. A fração final de alertas foi 2,93%. No teste posterior, a elegibilidade física foi 22,59%, a retenção contextual foi 11,63% e a fração final de alertas foi 2,63%. Três famílias de condições físicas apareceram nos dois períodos.

Esses resultados não são taxa de acerto para dano. Eles medem estabilidade de um detector híbrido sob critérios operacionais definidos antes da abertura do teste. A ausência de um alerta também não significa operação segura: pode significar apenas que não houve evidência suficiente naquela janela.

3. Personas

A solução atende dois lados do processo preventivo: o especialista da seguradora que precisa priorizar análise e o gestor que precisa entender a exposição da frota. O operador individual não recebe nota e não é uma persona avaliada pelo sistema.

3.1 Ana Martins, analista de riscos e inspeções na seguradora

Contexto. Ana trabalha na área técnica de seguros para máquinas agrícolas. Ela acompanha uma carteira com muitos equipamentos e precisa escolher quais casos merecem contato, vistoria ou acompanhamento preventivo.

Dores. A telemetria bruta é volumosa e difícil de comparar. Um simples limiar de RPM ou torque gera alarmes fora de contexto, enquanto um modelo caixa-preta não permite explicar por que uma máquina foi priorizada. Além disso, Ana não pode tratar um padrão operacional como dano confirmado ou usar um score experimental para negar cobertura.

Necessidades. Uma indicação rastreável até as amostras observadas; regras e limiares versionados; explicação das variáveis que tornaram a janela rara; visões de 7, 15 e 30 dias; e um fluxo em que a decisão final continua humana.

3.2 Carlos Mendes, cliente segurado e gestor de frota

Contexto. Carlos administra uma frota homogênea de tratores Fendt 314 e responde pela disponibilidade das máquinas, pelo planejamento de manutenção e pela interlocução com a seguradora.

Dores. Ele recebe muitos dados, mas pouca informação acionável. Alertas sem contexto confundem trabalho pesado legítimo com exposição atípica. Também não quer um sistema de vigilância de operadores nem uma pontuação que pareça acusar mau uso sem inspeção.

Necessidades. Uma visão clara de quando, por quanto tempo e em qual regime uma condição ocorreu; histórico persistido por máquina; evidência suficiente para planejar uma inspeção; e linguagem que diferencie alerta preventivo de diagnóstico de falha.

4. Arquitetura Proposta

A arquitetura foi desenhada para manter contratos e decisões de aplicação separados de HTTP, ORM, banco e formato do arquivo. O projeto não adiciona um modelo DDD completo: usa uma *clean architecture* pragmática, suficiente para deixar a IA testável e trocar os adaptadores externos sem duplicar a regra de negócio.

4.1 Clean Architecture

As responsabilidades são organizadas em cinco áreas:

- `features/`, `modeling/` e `streaming/`: núcleo científico que define o

esquema de 43 features, regimes, raridade, regras híbridas, agregação longitudinal, replay e formação causal das janelas.

- `application/`: contratos imutáveis, *ports* e casos de uso para frota, ingestão de janelas, telemetria, prioridades e inspeções.
- `infrastructure/`: adaptadores de arquivo, PostgreSQL, replay persistido, modelo congelado e cliente HTTP.
- `api/`: validação do transporte, rotas FastAPI e composição das dependências por requisição.
- `frontend/`: apresentação React para demonstração, portfólio, frota, detalhe do trator, telemetria e casos de inspeção.

A aplicação conhece apenas os *ports*. O modelo congelado implementa `UsageModel`; os repositórios PostgreSQL implementam os contratos de persistência. FastAPI e SQLAlchemy ficam nos limites externos. Essa separação permite testar o caso de uso com objetos em memória e testar os adaptadores com um banco real.

A composição executável mantém apenas o PostgreSQL em Docker, usando a imagem oficial sem customização. O comando `make demo-real` espera o banco ficar saudável e executa `scripts/demo_real.py` no host. O script valida os artefatos, aplica migrations, importa a telemetria, inicia FastAPI e Vite e realiza o replay pela API. Essa opção reduz a infraestrutura necessária e deixa explícita a integração entre dados, modelo, backend e frontend.

O progresso visual do replay é efêmero e mantido em memória pelo processo da demonstração. Janelas, decisões, explicações e casos de inspeção continuam persistidos exclusivamente no PostgreSQL.

4.2 Fluxo de Dados Ponta a Ponta

O caminho suportado começa no recorte observado do Zenodo. A importação persiste missões e amostras em uma transação. O replay lê apenas o PostgreSQL e constrói janelas causais. Cada janela pronta é enviada por HTTP para a API. O servidor não confia cegamente nas 43 features recebidas: reconstrói a janela a partir das amostras persistidas, compara todos os valores e só então chama o bundle. A decisão e sua explicação são persistidas antes de aparecer no progresso da demo ou no dashboard (Figura 1).




Figura 1. Fluxo executável da telemetria observada ao dashboard.

DIREÇÃO DAS DEPENDÊNCIAS DE CÓDIGO

A Figura 1 mostra o fluxo; aqui as setas indicam quem conhece quem no código.




Figura 2. Direção das dependências entre composição, adaptadores,

aplicação e núcleo científico.

4.3 Componentes e Contratos

Componente	Contrato principal	Responsabilidade
Composição	make demo-real	iniciar PostgreSQL e executar a demonstração local
Orquestração	scripts/demo_real.py	validar, migrar, cadastrar, importar, servir, reproduzir e verificar
Importação	ImportTelemetryUseCase.execute()	validar origem, persistir import, missões e amostras atômicamente
Replay	PostgresTelemetryReplay.iter_samples()	ler telemetria persistida em ordem causal
Janela	CausalWindowAggregator.ingest()	produzir READY ou NO_DATA sem usar o futuro
Transporte	POST /v1/tractors/{id}/windows	receber uma alegação de janela observada
Verificação	resolve_observed_window()	reconstruir a janela no servidor e rejeitar divergências
Modelo	UsageModel.score()	produzir regime, raridade, regra e alerta explicável
Persistência	insert_window()	gravar janela e decisão na mesma transação
Agregação	UsageModel.aggregate()	calcular exposição relativa em 7, 15 e 30 dias
Inspeção	casos de uso de inspection_cases	congelar evidência e registrar acompanhamento humano
Apresentação	API + dashboard	expor progresso, frota, prioridade, detalhe e casos
Progresso	InMemoryReplayProgress	projetar a execução atual sem substituir a evidência persistida

Tabela 2. Componentes executáveis e contratos do caminho principal.

O contrato HTTP exige `telemetry_import_id`, `split train` ou `validation` e proveniência `observed_dataset_replay`. Payload inválido recebe HTTP 422; linhagem ou conteúdo divergente, 409; criação, 201; repetição idêntica, 200. A concorrência é serializada por lock do trator e a idempotência combina modelo, trator, import, missão, janela e timestamp.

5. Modelagem, Hibridização e Avaliação

A modelagem foi construída para responder a uma pergunta sem rótulo de dano. Cada componente recebe uma função distinta: caracterizar o contexto, medir raridade, aplicar conhecimento físico e resumir a exposição no tempo (Tabela 3).

Componente	Método	Papel	Motivo da escolha
Pré-processamento	mediana + <code>RobustScaler</code>	preparar as 43 features	reduzir efeito de ausências e escalas distintas usando apenas treino
Regimes	K-Means, 3 grupos	contextualizar a operação	evita comparar diretamente trabalhos operacionais diferentes
Raridade	Isolation Forest por regime	medir atipicidade	método não supervisionado adequado à ausência de rótulos [2]
Regras físicas	cinco condições versionadas	exigir relevância operacional	torna o motivo do alerta explícito e auditável
Detector híbrido	regra física AND raridade	emitir alerta	reduz alarmes puramente estatísticos ou puramente limiares
Longitudinal	percentis empíricos de treino	resumir 7/15/30 dias	produz comparação relativa sem inventar probabilidade de dano

Tabela 3. Componentes da modelagem e justificativa metodológica.

5.1 Janelas Causais e Features

Cada missão é dividida em janelas de 60 segundos. A primeira amostra da janela usa somente o predecessor causal necessário para calcular variações de um segundo; nenhuma amostra futura participa. Uma janela é `READY` quando possui cobertura suficiente e contexto causal; caso contrário, vira `NO_DATA` e não é pontuada.

O modelo recebe 43 features: média e desvio-padrão de 17 sinais de estado (34 colunas) e média, desvio-padrão e máximo de três sinais transitórios (9 colunas). Identidade, tempo, split, trabalho, modelo de trator, temperatura de saúde e durações das regras físicas são excluídos das features aprendidas. Essa separação evita *leakage* e impede que a regra que autoriza o alerta seja também o atalho pelo qual o modelo aprende raridade.

5.2 Regimes Operacionais por K-Means

O experimento compara K-Means e Gaussian Mixture entre três e oito componentes, com cinco sementes. Todos os ajustes usam apenas treino. A validação exige silhueta mínima de 0,20, estabilidade ARI mínima de 0,75, pelo menos 1% do treino em cada grupo e ao menos três dimensões interpretáveis por regime. Entre os candidatos aprovados, vence aquele com maior estabilidade e silhueta. O artefato congelado selecionou K-Means com três regimes. O método deriva do problema de particionamento formulado por MacQueen [3].

O regime não é uma classe de risco nem um tipo de trabalho rotulado. Ele é um contexto estatístico para evitar que, por exemplo, uma janela de esforço com implemento seja comparada diretamente a uma janela de deslocamento leve.

5.3 Raridade Contextual por Isolation Forest

Depois do pré-processamento e da atribuição de regime, uma Isolation Forest com 300 árvores é ajustada para cada grupo. O score de raridade é o negativo de `score_samples`, de forma que valores maiores indiquem maior atipicidade. O limiar de cada regime é o quantil 0,97 de seus escores no treino. A validação nunca recalibra o limiar.

A explicação contextual usa a mediana e o intervalo interquartil do treino no regime. Para uma janela alertada, o sistema retorna as três features com maior desvio robusto. Isso não explica causalidade; explica quais dimensões mais se afastaram da referência estatística usada pelo detector.

5.4 Regras Físicas e Alerta Híbrido

As regras são calculadas amostra a amostra e acumuladas em segundos dentro da janela. Uma condição torna a janela fisicamente elegível quando dura pelo menos cinco segundos (Tabela 4).

Condição	Regra por amostra
<i>Lugging</i>	$600 \leq \text{RPM} < 1400$ e carga do motor $> 70\%$
Sobrecarga de torque	carga $> 90\%$ e torque atual $> 85\%$
Patinagem sob carga	carga $> 50\%$, patinagem $> 20\%$ e velocidade no solo $\geq 0,5 \text{ m/s}$
Térmica sob carga	carga $> 70\%$ e temperatura do arrefecimento $\geq 95 \text{ }^{\circ}\text{C}$

Condição	Regra por amostra
Subida brusca de torque	variação de torque em 1 s $\geq$ 35 e carga $>$ 70%

Tabela 4. Regras físicas versionadas usadas pelo detector híbrido.

Formalmente:

```
elegível_física = duração_de_qualquer_regra  $\geq$  5 segundos
raridade_contextual = score_do_regime  $\geq$  quantil_0,97_do_treino
alerta_híbrido = elegível_física AND raridade_contextual
```

As regras são hipóteses de engenharia. Elas tornam o alerta observável e auditável, mas não provam abuso, desgaste, dano ou falha.

5.5 Score Longitudinal

O sistema mede três taxas por hora observada:

- segundos de exposição física por hora;
- segundos de exposição alertada por hora;
- episódios de alerta por hora.

Cada taxa é convertida em percentil contra a distribuição empírica de treino do mesmo horizonte. O score relativo é a média simples dos três percentis:

```
score_relativo = média(
    percentil_exposição_física,
    percentil_exposição_alertada,
    percentil_episódios
)
```

O resultado varia de 0 a 100 e significa posição relativa no histórico de treino, não probabilidade de sinistro. A confiança depende da cobertura civil: abaixo de 25%, **LOW**; de 25% até menos de 60%, **MEDIUM**; a partir de 60%, **HIGH**. Ausência de telemetria produz **NO_DATA**, nunca zero exposição.

5.6 Avaliação e Resultados

Métrica	Validação	Teste temporal consumido
Janelas	2.522	3.617
Janelas fisicamente elegíveis	40,40%	22,59%
Retenção pela raridade	7,26%	11,63%
Alertas	74 (2,93%)	95 (2,63%)
Episódios	68	79
Episódios por hora observada	1,618	1,311
Famílias físicas representadas	3	3
Explicações completas	sim	sim
Decisão	GO	GO final

Tabela 5. Evidência temporal congelada do modelo híbrido.

O teste foi consumido uma única vez. Reexecutá-lo verifica o software, mas não cria nova evidência de generalização. A aplicação carrega somente o bundle cujo SHA-256, tamanho, versão, esquema de features e parâmetros coincidem com o manifesto. O arquivo atual possui 2.921.962 bytes e SHA-256 24b39996b3d0016f2bb29c6d722a24c46ac90576aab3da78cf44acdbad9cf5a4.

6. Dados, Dispositivos e Variáveis

6.1 Fonte e Aquisição

Götz e colaboradores instrumentaram cinco tratores, de 77 a 240 kW, em uma fazenda no sul da Alemanha. Os pesquisadores registraram GNSS de alta resolução, dados do barramento de motor J1939 e do ISOBUS, além de informações sobre modelos e implementos [1]. O conjunto público totaliza aproximadamente 2,8 GB; o arquivo Fendt_314.zip possui cerca de 1,1 GB.

O projeto não lê J1939 ao vivo. Ele usa o CSV consolidado publicado para o Fendt 314, convertido para um contrato canônico de 1 Hz. Essa diferença é importante: os sinais têm origem em barramentos reais, mas o runtime atual recebe arquivo canônico ou replay do PostgreSQL, não frames CAN de uma máquina conectada.

6.2 Reconstrução Temporal

O CSV consolidado contém `Time_(s)` como duração global, sem timestamp absoluto. Três arquivos de transporte preservam UTC e foram alinhados por sequências multivariadas de posição, RPM, torque, velocidade e tipo de trabalho. As três âncoras produziram a mesma origem:

```
epoch_utc = 2024-04-26T13:22:25.100Z
observed_at_utc = epoch_utc + Time_(s)
```

A coincidência ocorre na resolução original de 0,1 segundo. O tempo decorrido é preservado para auditoria. A reconstrução estabelece quando o sinal foi observado, mas não acrescenta qualquer rótulo de dano ou manutenção.

6.3 Catálogo de Variáveis

Grupo	Sinais usados na janela	Estatísticas do modelo
Motor e comando	RPM, torque atual, carga, acelerador	média e desvio-padrão
Movimento e implemento	eixo dianteiro, velocidade sobre o solo, velocidade do implemento, roda, PTO traseira	média e desvio-padrão
Engate e esforço	posição e estado do engate, força do elo, <i>draft</i> traseiro	média e desvio-padrão
Velocidades da máquina	velocidade no solo, selecionada e da roda	média e desvio-padrão
Dinâmica	patinagem	média e desvio-padrão
Transientes	subida de torque, mudança de RPM e mudança de velocidade em 1 s	média, desvio-padrão e máximo

Tabela 6. Formação das 43 features do contrato `usage_context_v2`.

O contrato bruto ainda carrega temperatura do arrefecimento para a regra térmica e campos de identidade para rastreabilidade. Eles não entram no vetor de 43 features aprendido. Os valores são validados contra faixas físicas antes da agregação; leituras inválidas viram ausência e são imputadas somente na fronteira do modelo com a mediana de treino.

6.4 Critérios de Aceite e Hipóteses

Gate	Critério
Integridade da fonte	tamanho, SHA-256 dos bytes e digest semântico devem coincidir
Causalidade	replay e janelas não podem usar amostras futuras
Regimes	$silhueta \geq 0,20$, estabilidade $ARI \geq 0,75$ e fração mínima de treino $\geq 1\%$
Detector	limiares ajustados somente no treino e explicações completas
Alerta	regra física ≥ 5 s e raridade acima do limiar do regime
API observada	toda janela precisa de import persistido e comparação integral das features
Persistência	decisão, explicação, versão e proveniência na mesma transação
Demo	152.561 amostras, 105 missões, 2.522 janelas e 74 alertas
Software	116 testes Python, incluindo 3 integrações PostgreSQL; 25 testes de frontend; lint, typecheck e build aprovados

Tabela 7. Principais critérios de aceite científico e de software.

As hipóteses centrais são que regimes reduzem comparações fora de contexto, que raridade condicionada ao regime filtra parte das regras físicas comuns e que episódios são mais úteis para inspeção do que alertas isolados.

O experimento mostra consistência temporal dessas hipóteses no histórico estudado; ainda não mede associação com desfechos mecânicos ou financeiros.

7. Cenário Ilustrativo

Durante a reprodução real da validação, a missão 331, janela 5, iniciada em 2024-09-30T17:34:10.100Z, foi classificada no regime operacional 2. A janela acumulou 19 segundos de sobrecarga de torque, cinco segundos de subida brusca de torque e 22 segundos de exposição física total. O score de raridade contextual foi 0,6276, acima do limiar 0,5722 daquele regime. Como a condição física sustentada e a raridade ocorreram juntas, o modelo emitiu alerta.

A explicação apontou como maiores desvios robustos a média da mudança de velocidade em um segundo, a média da mudança de RPM em um segundo e o máximo da mudança de RPM. Esses valores não dizem que o trator sofreu dano. Eles dizem que a combinação observada foi fisicamente relevante pelas regras versionadas e estatisticamente incomum dentro do contexto aprendido.

No fluxo de negócio, Ana visualiza o episódio e seu histórico de 7, 15 e 30 dias. Se a exposição for recorrente e houver cobertura suficiente, ela pode abrir um caso de inspeção. Carlos recebe a evidência temporal, verifica o uso do implemento e agenda uma avaliação de campo. O caso pode terminar como `NO_ACTION`, `MONITOR` ou `MAINTENANCE_RECOMMENDED`. Nenhuma dessas etapas registra culpa, confirma sinistro ou altera automaticamente preço e cobertura.

8. Governança e Conformidade

A governança é tratada em quatro frentes. Primeiro, **proveniência**: cada decisão referencia import, split, hash semântico, trator, missão, janela, versão do modelo e fingerprint do conteúdo. A API reconstrói a janela no servidor, o que impede que um cliente associe features arbitrárias a uma origem legítima.

Segundo, **governança do modelo**: treino, validação e teste seguem a ordem temporal; o teste está marcado como consumido; o bundle é imutável e verificado por hash; e as regras físicas permanecem fora do vetor aprendido. Mudanças de features, limiar, regras ou baseline exigem nova versão e nova avaliação.

Terceiro, **uso responsável no seguro**: o score é evidência para prevenção e priorização. Não deve decidir sozinho prêmio, cobertura, recusa de indenização, culpa ou mau uso. Produção atuarial exigiria dados de múltiplas unidades, desfechos confirmados, análise de viés, validação prospectiva e governança regulatória própria.

Quarto, **privacidade e segurança**: o recorte público utilizado não contém identidade pessoal declarada e o contrato atual não avalia operador. Em uma implantação real, telemetria de equipamento pode se tornar dado associado a pessoas ou empresas; seriam necessários base legal, transparência, minimização, retenção e controles compatíveis com a LGPD [10]. O MVP não possui autenticação. PostgreSQL, API e frontend escutam somente em 127.0.0.1. Esse limite local não deve ser confundido com autorização para exposição externa.

9. Conclusão

Este trabalho demonstrou uma avaliação de telemetria do Fendt 314 baseada em dados observados e em uma cadeia completa de IA aplicada. O modelo combina regimes K-Means, raridade por Isolation Forest e cinco regras físicas versionadas. A decisão é explicável, causal e agregada em horizontes de 7, 15 e 30 dias. A validação temporal produziu 74 alertas em 2.522 janelas e o teste posterior, 95 em 3.617, preservando três famílias físicas e explicações completas.

A principal contribuição não é afirmar que o sistema prevê dano. É mostrar que, diante da ausência desse rótulo, ainda é possível construir um produto acadêmico útil e honesto: detectar exposição contextual, persistir evidência, entregar uma API e um dashboard, e apoiar uma decisão humana de inspeção. A demo real importa 152.561 amostras observadas, executa o bundle congelado e reproduz 2.522 decisões por HTTP com verificação no PostgreSQL. O fluxo completo parte de `make demo-real`: somente o banco usa Docker; API, replay e frontend rodam localmente, e a suíte automatizada fecha o caminho de software.

O resultado atual é válido para o histórico de uma unidade Fendt 314. Levar a solução a uma frota real requer novas unidades, telemetria própria por trator e validação externa. Essa limitação não reduz o valor da POC; define com precisão qual problema ela já resolve e qual evidência ainda precisa ser construída.

10. Planejamento e Divisão de Tarefas

10.1 Roadmap

Fase	Entregáveis
Fase 1 — implementada	reconstrução temporal; 43 features causais; K-Means e Isolation Forest por regime; regras físicas; score 7/15/30; bundle congelado; recorte observado versionado; PostgreSQL em Docker; API e dashboard locais; casos de inspeção; demo real e testes automatizados
Fase 2 — validação externa	telemetria própria de múltiplos Fendt 314; gateway J1939/ISOBUS; contrato canônico ao vivo; validação entre unidades, implementos e propriedades; associação prospectiva com inspeções e manutenção confirmada
Fase 3 — produto segurador	autenticação e autorização; segurança e observabilidade; infraestrutura cloud; governança LGPD; piloto com seguradora e gestores; avaliação de impacto preventivo; eventual modelagem supervisionada somente se houver desfechos confiáveis

Tabela 8. Roadmap de evolução baseado nas lacunas de evidência atuais.

O roadmap não prevê acrescentar modelos apenas por complexidade. Novas técnicas só entram quando houver uma pergunta mensurável e dados que permitam validá-la. Em particular, previsão de dano, vida útil remanescente ou sinistro não deve ser implementada antes de existirem rótulos temporais confiáveis.

10.2 Divisão de Responsabilidades

Trilha	Responsabilidades	Responsável
Trilha A — dados e modelagem	estudo do dataset; reconstrução e qualidade dos sinais; engenharia das 43 features; regimes; raridade; regras físicas; protocolo de avaliação temporal	Karina Queiroz de Gennaro (RM 570928)
Trilha B — arquitetura e backend	contratos de aplicação; PostgreSQL e migrations; importação e replay; API; integração do bundle; idempotência, proveniência e demo ponta a ponta	Luis Felipe Bardi (RM 569479)
Trilha C — produto, frontend e governança	personas e jornada; dashboard; prioridades e inspeções; análise dos resultados; limites de uso no seguro; redação e revisão acadêmica	Beatriz de Oliveira Ossola Ribeiro (RM 570190)
Compartilhada	decisões de escopo; revisão cruzada; testes; manutenção do repositório; apresentação e vídeo para a banca	Karina, Luis Felipe e Beatriz

Tabela 9. Divisão proposta das responsabilidades do projeto.

10.3 Práticas de Coordenação

O grupo adota sincronização semanal curta, quadro Kanban, revisão cruzada antes de integração, contratos versionados e critérios de aceite executáveis. Decisões materiais são registradas antes da implementação; mudanças no modelo exigem repetição dos gates; e a documentação distingue sempre evidência experimental, resultado da execução atual e trabalho futuro.

11. Referências

- [1] GÖTZ, K. et al. **Agricultural Load Cycles: Tractor Mission Profiles From Recorded GNSS and CAN Bus Data**. Zenodo, versão 1, 2025. DOI: 10.5281/zenodo.14619787.
- [2] LIU, F. T.; TING, K. M.; ZHOU, Z.-H. **Isolation Forest**. In: *2008 Eighth IEEE International Conference on Data Mining*. IEEE, 2008. DOI: 10.1109/ICDM.2008.17.
- [3] MACQUEEN, J. **Some Methods for Classification and Analysis of Multivariate Observations**. In: *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, v. 1, p. 281–297, 1967.
- [4] PEDREGOSA, F. et al. **Scikit-learn: Machine Learning in Python**. *Journal of Machine Learning Research*, v. 12, n. 85, p. 2825–2830, 2011.
- [5] SCIKIT-LEARN DEVELOPERS. **Scikit-learn User Guide**. Disponível em: https://scikit-learn.org/stable/user_guide.html. Acesso em: ago. 2026.
- [6] POSTGRES GLOBAL DEVELOPMENT GROUP. **PostgreSQL 16 Documentation**. Disponível em: <https://www.postgresql.org/docs/16/>. Acesso em: ago. 2026.
- [7] FASTAPI. **FastAPI Documentation**. Disponível em: <https://fastapi.tiangolo.com/>. Acesso em: ago. 2026.

- [8] SQLALCHEMY AUTHORS. **SQLAlchemy 2.0 Documentation.** Disponível em: <https://docs.sqlalchemy.org/en/20/>. Acesso em: ago. 2026.
- [9] META OPEN SOURCE. **React Documentation.** Disponível em: <https://react.dev/>. Acesso em: ago. 2026.
- [10] BRASIL. **Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).** Diário Oficial da União, Brasília, 2018.
- [11] SEIVA. **Model Card: Fendt 314 Hybrid v2.0.1.** Documento técnico interno do projeto, 2026.
- [12] SEIVA. **Contract Path: Avaliação de Telemetria do Fendt 314.** Documento técnico interno do projeto, 2026.
- [13] SOMPO SEGUROS. **Apresentação Institucional — Enterprise Challenge FIAP.** 2026.